Université de Rouen-Normandie

Module : Introduction aux Humanités numériques

Sous la supervision : Mme Ing Lucence

Objet : Devoir final du cours Introduction aux humanités numérique

Réalisé par : Fatima Hamidi

Spécialité : Master 1 Humanités numériques

Année universitaire : 2025-2026

La transcription automatique :

Le domaine de l'analyse et de la reconnaissance de documents (Document Image Analysis and Recognition, DIAR) s'intéresse à l''étude et au traitement automatique des documents numérisés. À ses débuts, la recherche s'est principalement concentrée sur la reconnaissance de texte imprimé à travers les systèmes d'OCR, avant de s'étendre progressivement à la reconnaissance de l'écriture manuscrite HTR.

Avant de passer à l'évaluation historique de la transcription automatique de texte, nous définissons d'abord ce qu'est l'ATR (Automatic Text Recognition). En français, l'ATR correspond à la reconnaissance automatique de texte. Il s'agit d'une technologie qui utilise l'intelligence artificielle pour transformer des contenus textuels présents sous forme d'images, qu'ils soient imprimés ou manuscrits et les rendre en texte numérique, afin de pouvoir les exploiter et les utiliser dans la recherche.

Cette technologie repose sur des techniques d'apprentissage automatique, qui nécessitent des données d'entrainement annotées par l'humain afin de créer des modèles adaptés aux besoin de la recherche. La performance ou le résultat des modèles obtenus dépend fortement de la qualité des données d'entrainement, de leur diversité, ainsi que du degré de ressemblance avec les documents à transcrire.

Cette méthode se distingue principalement de deux approches : la première est la reconnaissance optique de caractère, abrégée en (OCR), elle est appliquée aux textes imprimés. La deuxième approche est la reconnaissance de l'écriture manuscrite (HTR), qui concerne les documents manuscrits écrit par la main. Cette dernière repose sur des techniques d'intelligence artificielle et d'apprentissage automatique de l'IA, ou la transcription semi-automatique qui utilise le participatif pour corriger et annoter les documents en post traitement, et cela est utile pour la recherche et la réalisation des projets en humanités numériques.

Donc, l'ATR constitue un cadre général qui englobe deux méthodes principales : l'OCR, dédié à la reconnaissance du texte imprimé, et l'HTR, spécialisé dans la reconnaissance de l'écriture manuscrite. Ces deux méthodes permettent ainsi de réaliser les différents formats et types de transcription.

Les outils d'OCR et d'HTR à la base permettent d'extraire un texte initialement disponible sous forme d'image afin de le transformer en texte numérique facile à exploiter. Ce processus contient plusieurs formes d'analyse, telles que la fouille de données, la recherche textuelle ou l'analyse computationnelle.

La transcription automatique désigne alors l'ensemble des méthodes informatiques qui permettent de transformer ou rendre un contenu visuel ou audio (sonore) en texte lisible en utilisant des algorithmes, par une machine. Dans le cadre des humanités numériques la transcription automatique constitue un outil essentiel pour l'analyse, la préservation et la diffusion des sources textuelles.

Evolution historique de la transcription automatique :

En premier temps, la transcription automatique apparait comme premières formes avec la reconnaissance vocale, de la parole, connue sous le nom d'ASR (Automatic Speech Recognition), développée dès le milieu du XXe siècle, visant à transformer un signal sonore en texte exploitable.

Ensuite, l'OCR se développe et les recherches se sont étendues à la reconnaissance optique de caractères, abrégée en (OCR), qui permet la transcription automatique de textes imprimés à partir d'images numérisées. Le cadre de la numérisation marque un développement notable dans la numérisation des différents formats écrits (livres, notamment historique, journaux...etc), particulièrement pour les langues latines.

Dès les années 1990, ces technologies ont trouvé des applications concrètes, notamment dans l'automatisation postale. Le développement du domaine a été lié à l'essor des réseaux de neurones artificiels[1], dont les performances se sont améliorées avec l'introduction de l'algorithme de rétropropagation.

Par la suite, l'intérêt pour ces méthodes s'est élargi avec les projets de bibliothèques numériques, dont l'objectif était de rendre les documents numérisés accessibles, indexables et exploitables, en particulier les documents anciens conservés dans les bibliothèques patrimoniales.

Depuis une dizaine d'années, l'essor du Deep Learning a profondément développé les approches en reconnaissance automatique des documents. Ces nouvelles méthodes ont permis des progrès significatifs dans la transcription automatique, y compris pour des documents complexes tels que les manuscrits historiques. Afin de mesurer l'impact des réseaux de neurones dans le domaine d'analyse et de la reconnaissance de documents, une analyse des articles lors des ICDAR[2] a été réalisée sur les travaux qui utilisent des techniques c'est à dire fondées sur les réseaux neurones artificiels.

Le résultat de cette analyse montre une évolution de l'usage de ces méthodes au fil du temps. La première phase d'intérêt apparait au milieu des années 1990, et la deuxième phase commence avec la recherche sur les réseaux de neurones entre 2007 et 2011. Ensuite à partir de 2013, l'introduction des approches basées sur le Deep Learning entraine une augmentation rapide et continue de l'utilisation des réseaux de neurones dans ce domaine. En 2019, ces méthodes représentent une très large majorité des travaux publiés ce qui témoigne de leur rôle dans les recherches actuelles en reconnaissance automatique des documents.

Les étapes à suivre pour la transcription automatique des documents historiques :

[1] Réseaux de Neurones Artificiels : sont des modèles mathématiques inspirés du fonctionnement des neurones biologique. Ils sont au cœur de deep learning et de l'intelligence artificielle.

[2] ICDAR : Conférence internationale sur l'analyse de documents et de reconnaissance.

En premier lieu, on commence par le prétraitement des images (Pre-Processing) : qui consiste au nettoyage et amélioration de la qualité des images numérisées, il a deux opérations principales lesquelles sont : 1/ amélioration d'image (Image Enchancement) : sa fonction consiste en la réduction du bruit et la restauration des caractères endommagés.

2/Binarisation (Image Binarization) : cette opération concerne la transformation de l'image en couleurs noir et blanc pour séparer le texte et le fond.

Ensuite, la deuxième étape est l'analyse de la mise en page (Lay-out Analysis) : pour identifier la structure du document : colonnes, lignes de texte, tableaux et annotations...etc. Puis, la segmentation des lignes de texte (Text Line Segmentation) : cette étape détermine l'emplacement exact de chaque ligne, ce qui particulièrement difficile pour les manuscrits historiques à lignes irrégulières ou décorations.

(Segmentation des zones (Zone, Patch classification) : la segmentation des zones différencie le texte principal, annotations, décorations et arrière-plan.

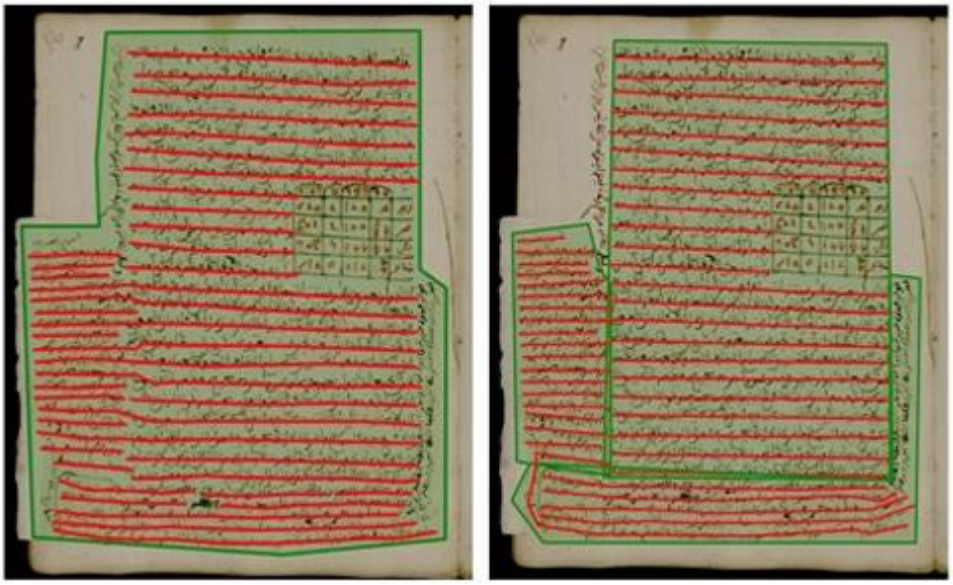

La troisième étape est :la reconnaissance des caractères et transcription (Character Word Recognition), après avoir isolé les lignes ou les zones de texte, chaque caractère est reconnu automatiquement à l'aide de modèles HTR (Handwritten Text Recognition) ou OCR et Keyword spotting, par recherche de mots-clés dans les documents et la détection de texte complexe dans le cas des documents historiques.

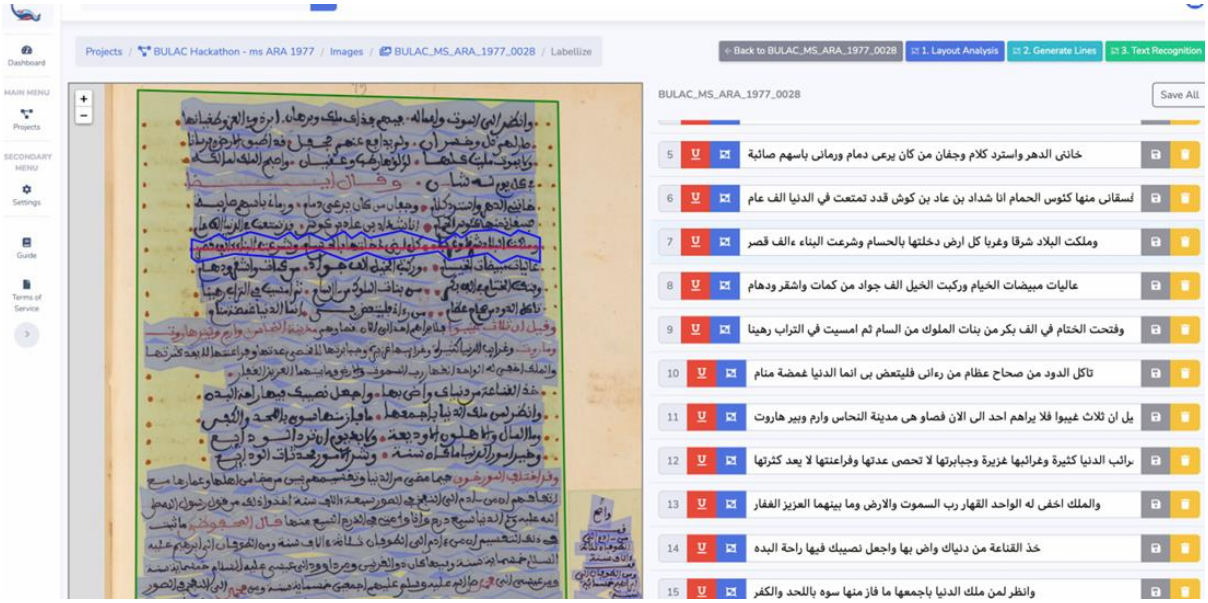

Input-Output relations : elle contient deux éléments la première est l'entrée : page entière, zones homogènes, lignes de texte, et la deuxième est : sortie : pixels classifié, lignes détectées, caractère reconnus et la transcription complète. Passant à l'étape de Données et environnement expérimentale : en utilisant des Framework, tels que : open source eScriptorium, HistCorp..ect

Enfin, Post-traitement et correction : vérifie des résultats de la transcription et les corrections manuelles par l'humain ou automatique, afin de produire un texte numérique exploitable pour l'analyse linguistique et historique.

Ces dernières années, et grâce au web 3.0 et aux avancées en intelligence artificielle et en apprentissage profond, la transcription automatique s'est développée aux manuscrits à travers la technologie HTR (Handwritten Text Recognition). Cette évolution marque un tournant majeur pour la bonne exploitation des archives historiques, en particulier pour les écritures et les manuscrits complexes et non standardisés comme la langue arabe.

Cependant, si ces technologies ont atteint un haut niveau de performance pour les langues latines, leur application aux langues non latines demeure un défi majeur, la langue arabe, en particulier présente des spécificités liées à la diversité des graphies, à l'écriture cursive et à la présence de diacritique ou encore l'absence de standardisation orthographique dans les manuscrits anciens, qui rendent la connaissance automatique plus complexe que pour les langues latines.

Donc, ce travail étudie l'utilisation de la transcription automatique dans le cas des langues non latines, en prenant la langue arabe comme étude de cas.

Cette réflexion s'inspire de plusieurs exemples d'articles et de projet de recherche qui utilisent la méthode de la transcription automatique, en particulier appliquée aux graphies et à la langue arabe. Parmi ces exemples, on peut citer le rapport rédigé par Noémie Lucas intitulé "OCR/HTR et graphie arabe : Les manuscrits arabes à l'heure de la reconnaissance automatique des écritures, publié en 2022". Ce rapport réalisé dans le cadre du consortium

DISTAM (Digital Studies Africa, Adia, Middle EASt), fait un point complet sur les progrès concernant la reconnaissance automatique des écritures arabes, notamment pour les manuscrits, et présente les enjeux rencontrés lord de la transcription de texte en langue non latine.

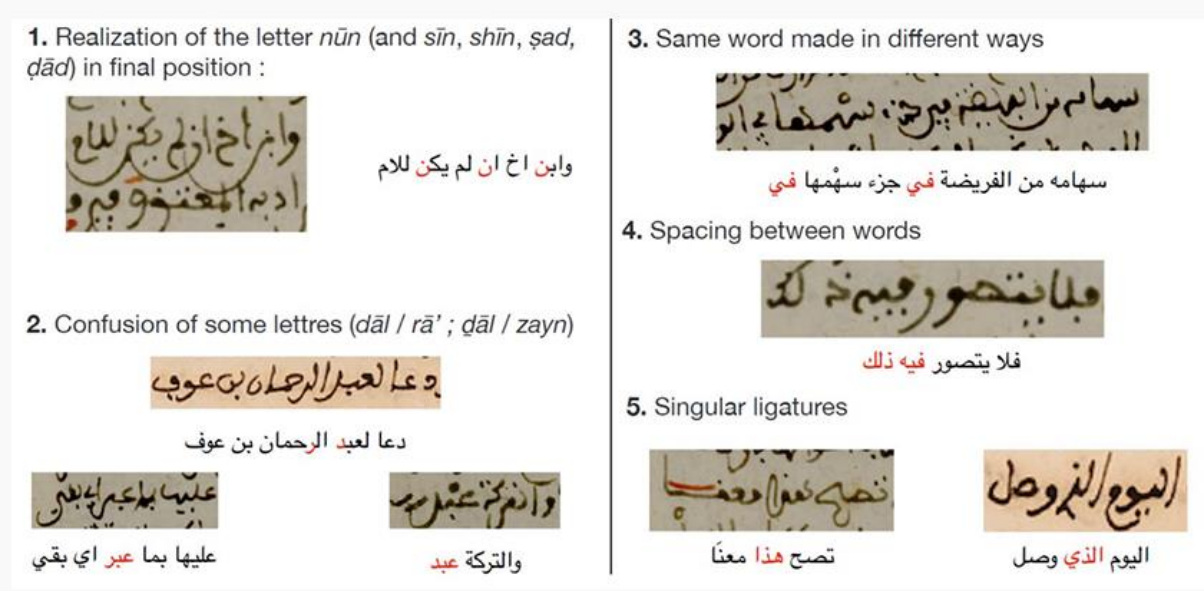

Spécificités et enjeux de l'écriture arabe

On trouve également l'article Graphies Arabes et Transcription Automatique : Vers une Reconnaissance Textuelle Haute Précision, qui retrace les progrès réalisés dans la transcription des écritures arabe via des projets de création de données et de modèles HTR (Handwritten Text Recognition).

Parmi les projets analysés dans cet article, plusieurs corpus jouent un rôle central dans l'avancement de la transcription automatique des graphies arabes :

1. RASAM 1 et RASAM 2 : (Recognition and Analysis of Scripts in Arabic Maghrebi) sont des jeux de données développés pour la reconnaissance des écritures manuscrites maghrébines. Ils comprennent des manuscrits annotés avec leur transcriptions, permettant l'entrainement et l'évaluation de modèles HTR spécialisés.
2. TARIMA : a pour objectif principal est de l'amélioration des performances de la reconnaissance automatique des manuscrits maghrébins et la participation à l'enrichissement des sources disponibles pour les HTR en arabe.
3. ISKANDAR : est développé dans le cadre du projet ANR LiPoL, qui porte sur des manuscrits en arabe oriental, et participe aussi à la constitution de corpus diversifiés (arabe de Maghreb et de moyen orient), pour la transcription automatique de textes historiques dans différentes variantes de la langue arabe.

Comme, on a déjà précisé que chaque projet se concentre sur un type spécifique de manuscrits ou graphies (écriture maghrébines, orientale et lithographies), et offre des données structurés et disponibles en formats XML, ainsi que des modèles HTR pour des corpus variés. Enfin,

l'article privilégie l'utilisation de ressources en ligne (GitHub et GitLab) pour accéder facilement aux données et aux modèles utilisés dans ces projets, permettant une exploration des méthodologies de transcription automatique appliquées à la langue arabe.

La mise en évidence de l'intérêt de la proche de transcription automatique :

Selon le projet RASAM 1 se concentre sur les manuscrits arabes maghrébins, souvent très difficile à transcrire manuellement en raison de la cursivité des ligatures et des variations de langage régionales, et parfois le style de l'écriture rendre la séparation et la distinction des lettres difficile. Mais grâce à l'utilisation de l'HTR, le projet RASAM 1 et les autres projets permettent de produire des transcriptions numériques annotés, reproductibles et exploitables pour l'analyse textuelle et linguistique de corpus. On aperçoit que HTR applique les principes F.A.I.R qui visent à rendre le manuscrit en données plus accessible et comprises.

Ainsi que, les images annotées du projet montrent davantage la différence entre la lecture manuelle et la transcription automatique, en mettant en lumière les formes de lettres plus complexes et difficiles à distinguer et en particulier, les diacritique de la langue arabe qui sont omniprésents, notamment dans la poésie et les vers, mais aussi la prose.

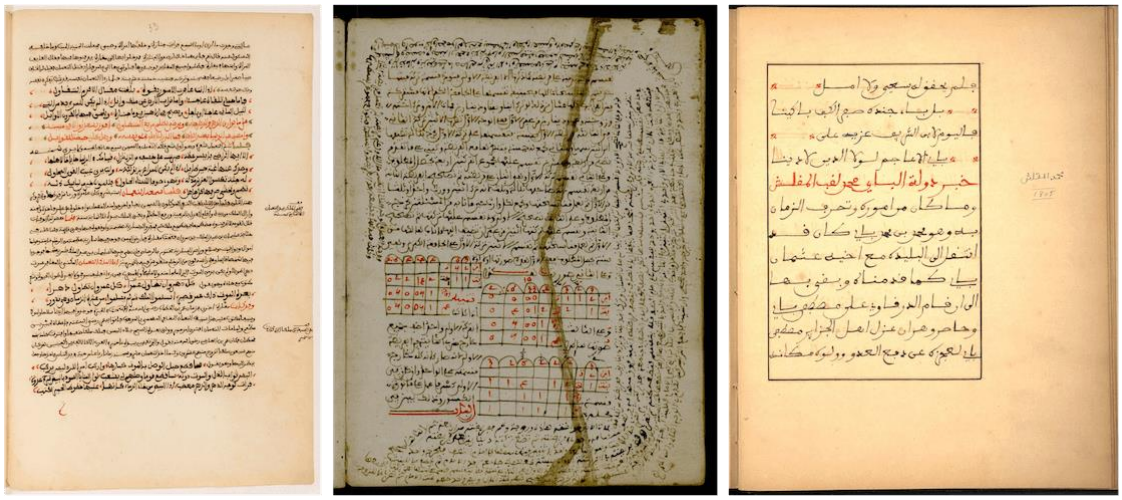

Styles d'écritures différents et variées

La comparaison entre les deux différents formats :

Concernant la partie de comparaison, on prend deux versions d'écritures différentes, ensuite nous analyserons les points en commun et les spécificités de chaque version. Nous analyserons d'abord la transcription automatique avec les fichiers XML, Ground Truth en mesurant la précision de transcription pour chaque manuscrit et pour le corpus de façon général.

La version XML, rend la transcription plus claire et compréhensible, les lettres sont bien claires, les mots sont séparés, nous pouvons lire très facilement le texte en version XML.

Nous pourrons ainsi remarquer une transcription automatique fiable du modèle RASAM 1 qui permet de produire des transcriptions numériques exploitables pour l'analyse linguistique ou textuelle de texte. L'avantage majeure aussi est le gain de temps, car ce qui nécessiterait des heures de travail manuel avant, peut être réalisé en quelques minutes par le modèle utilisé.

Concernant l'adaptation à une langue sous-dotée : les modèles classiques OCR/HTR pour les langues latines ne fonctionnent pas bien sur l'arabe manuscrit, et le projet RASAM 1 montre parfaitement ce détail, donc il est désormais important de créer des outils spécifiques à chaque langue et graphie. Cependant l'application est toujours possible dans l'analyse de corpus historique, études philologiques et pour la conservation numérique et la diffusion scientifique par la suite des manuscrits.


```
Code  Blame  316 lines (316 loc) · 44.9 KB                                                    Raw
156          </TextEquiv>
157        </TextLine>
158        <TextLine id="l_b-A03D22">
159          <Coords points="534,3098 534,3040 651,3057 682,3036 727,3053 751,3036 772,3047 841,3029 872,3047 900,3022 937,3022 968,3043 1041,3036 1058,3016 1144
160          <Baseline points="535,3100 2586,3009"/>
161          <TextEquiv>
162            <Unicode>علماء البيان ان الاسم دال على الثبوت ولم يفصلوا بين صفة مشبهة وغيرها تحقيقا او تقديرا</Unicode>
163          </TextEquiv>
164        </TextLine>
165        <TextLine id="l_b-A03D23">
166          <Coords points="534,3171 534,3133 558,3122 672,3129 717,3112 758,3119 782,3102 817,3119 834,3105 858,3119 931,3098 975,3116 1027,3098 1068,3112 1093
167          <Baseline points="535,3173 2590,3087"/>
168          <TextEquiv>
169            <Unicode>وصفان قسم اليهما ثبوت المعنى اي ان الصفة المشبهة اما ان يكون معناها ثابتا ثبوتا محققا</Unicode>
170          </TextEquiv>
171        </TextLine>
172        <TextLine id="l_b-A03D24">
173          <Coords points="531,3253 531,3209 548,3191 658,3198 682,3184 731,3202 748,3181 772,3191 844,3178 872,3195 931,3195 955,3174 986,3188 1017,3171 1055,
174          <Baseline points="534,3255 2590,3155"/>
175          <TextEquiv>
176            <Unicode>كما في حسن وظريف ونحوهما واما ثبوتا مقدرا نحو متقلب تقول زيد متقلب الفكر</Unicode>
177          </TextEquiv>
178        </TextLine>
179        <TextLine id="l_b-A03D25">
180          <Coords points="531,3315 531,3278 544,3271 641,3260 679,3274 710,3253 731,3264 758,3250 831,3267 920,3247 982,3260 1041,3240 1055,3253 1068,3236 116
181          <Baseline points="532,3317 2588,3223"/>
182          <TextEquiv>
183            <Unicode>فالتقلب معنى ثابت للموصوف تقديرا لا تحقيقا اذ لا يجتمع التقلب والثبوت بالتحقيق</Unicode>
184          </TextEquiv>
185        </TextLine>
186        <TextLine id="l_b-A03D26">
187          <Coords points="548,3374 551,3329 620,3333 644,3312 668,3329 731,3312 782,3326 858,3309 927,3322 972,3302 1003,3319 1055,3298 1124,3315 1224,3291 12
```


Transcription en format XML de projet RASAM 1

À partir de cela, on aperçoit que le projet RASAM 1 illustre parfaitement l'intérêt de la transcription automatique appliquée aux manuscrits arabes, il démontre que :

Les méthodes numériques permettent un traitement rapide et standardisé des manuscrits, ne sont pas des méthodes limitées sur une seul format de manuscrit. Ainsi, comme on a remarqué sur l'adaptation des modèles aux spécificités linguistiques reste essentielle pour les langues sous-dotées comme l'arabe. Enfin, cette approche ouvre la voie à une analyse quantitative et qualitative, qui est difficile a réalisé avec seulement une approche humaniste traditionnelle.

```xml
<PcGts xmlns="http://schema.primaresearch.org/PAGE/gts/pagecontent/2013-07-15" xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance" xsi:schemaLocation="http://schema.primaresearch.org/PAGE/gts/pagecontent/2013-
  <Metadata>
    <Creator>Calfa</Creator>
    <Created>2021-07-01T07:05:02+00:00</Created>
    <Comments>RASAM Dataset (ICDAR 2021). Transcription carried out as part of the IA and Khatt Maghrebi hackathon (BULAC, GIS MOMM CNRS, Calfa). Description of the specifications available in the paper and on G
  </Metadata>
  <Page imageFilename="BULAC_MS_ARA_1977_0012.jpg" imageHeight="1417" imageWidth="920">
    <TextRegion id="r_a-1" custom="structure {type:text;}">
      <Coords points="57,77 725,85 735,1113 55,1129 57,77"/>
      <TextLine id="l_a-1">
        <Coords points="72,89 88,77 117,74 135,84 156,76 163,83 179,72 215,81 251,71 269,80 310,74 333,81 358,71 436,79 469,71 488,81 520,76 541,84 564,83 578,70 620,71 635,83 655,72 685,71 722,75 722,122 713,11
        <Baseline points="72,115 137,111 430,106 722,113"/>
        <TextEquiv>
          <Unicode>عليه وهو بكل شيء عليم قال وهب ابن منبه ثم خلق الله بعد خلق الروح</Unicode>
        </TextEquiv>
      </TextLine>
      <TextLine id="l_a-2">
        <Coords points="65,136 88,130 105,130 126,121 157,126 213,115 226,124 248,117 295,121 382,115 397,126 416,118 427,128 503,115 520,125 539,117 607,129 669,121 685,131 713,117 722,122 719,159 677,150 652,1
        <Baseline points="72,149 235,142 397,142 722,146"/>
        <TextEquiv>
          <Unicode>البهموت وهو حوت عظيم اسمه السرا الفاد الله على كاهل الروح والملك العظيم ثم</Unicode>
        </TextEquiv>
      </TextLine>
      <TextLine id="l_a-3">
        <Coords points="61,156 96,164 126,155 175,152 222,161 258,153 291,152 327,152 372,148 401,152 419,148 446,150 524,160 542,149 563,149 580,157 592,150 651,160 677,151 686,159 726,160 726,186 707,190 685,1
        <Baseline points="70,180 142,175 434,170 726,170"/>
        <TextEquiv>
          <Unicode>خلق الثور فوق الحوت ثم خلق الريح العقيم التي تحصى بها دار جهنم فهي مخزونة في انيف هنا</Unicode>
        </TextEquiv>
      </TextLine>
      <TextLine id="l_a-4">
```


La partie métadonnées de document :

Grâce à la version XML obtenue après la transcription de la partie métadonnées, nous observons une plus grande clarté et une meilleure organisation des informations relatives au document. L'élément creator permet d'identifier l'auteur du texte, tandis que created indique précisément la date de transcription (jour, mois et année). Le type de contenu à encoder est également spécifié, en l'occurrence un texte, avec des informations plus détaillées concernant les points de coordonnées et les liens de base (base links).

Cet encodage structuré nous permet plus tard de mieux comprendre les métadonnées essentielles du document. Il facilite surtout l'exploitation du texte en le rendant lisible par la machine, réutilisable et interopérable, en respectant les quatre conditions F.A.I.R, que ce soit pour la recherche ou pour la lecture de document. Cela montre ainsi la nécessité et l'importance de la transcription et l'encodage en XML, qui constitue un outil fondamental pour la valorisation, la réutilisation et l'exploitation durable des données et les rendre archivable.

Présentation détaillée de projet :

Le Projet RASAM 1(Reconnaissance Automatique des Scriptes Arabes Maghrébines), s'inscrit dans le cadre des humanités numériques appliquées aux manuscrits historiques arabes. Il vise à faciliter la transcription automatique des manuscrits arabes, généralement complexe à traiter avec les outils OCR ou par une transcription manuelle et une lecture humaine. Ce projet a plusieurs objectifs : premièrement il mit en œuvre un corpus annoté d'images de manuscrits arabes avec leurs transcription correspondantes en utilisant Ground Truth, afin de faciliter la visualisation du projet et de s'appuyer sur ces illustrations pour apprendre à utiliser cette méthode. Il développe et entraine des modèles de transcription automatique adaptés à l'écriture arabe, en tenant en compte de des spécificités linguistique. Enfin, il produit des résultats numériques pouvant être utilisés pour des analyses linguistiques et historiques qui faciliteront plus tard la recherche pour les chercheurs dans ce domaine.

Contexte du projet RASAM 1 : dans le cadre de projet RASAM 1 a été lancé en 2020 pour répondre aux spécificités et enjeux des écritures arabes, et plus particulièrement de la graphie maghrébine. Les manuscrits étudiés proviennent des collections patrimoniales de la BULAC, notamment les manuscrits MS.ARA.609 et MA.ARA.1977.

Objectifs du projet :

Le projet RASAM 1 poursuit plusieurs objectifs complémentaires :

Premièrement, la dimension technique et expérimentale : pour le développement et entrainement de modèles HTR pour l'arabe manuscrit, servant de preuve de concept.

Il fait le choix des écriture maghrébines, dans le but de valoriser les collections patrimoniales de la BULAC, et de s'inscrire dans le cadre du travail mené par le SIG MOMM sur le Maghreb et ses ressources.

Enfin, il contribue à la formation d'humanités numérique, en formant des futurs chercheurs et valorise l'usage des méthodes numériques pour l'étude des manuscrits.

Les caractéristiques du corpus du projet sont :

Le style d'écriture différents et courant :

Une variété de mises en page mais la variété thématique est limitée, car il focalise principalement en histoire et droit. Le corpus comprend 300 pages annotées par 14 transcripteurs, fournissant un jeu de données riches et structurés. La dataset de projet est disponible sous licence CCBY sur GitHub.

En ce qui concerne le déroulement du projet et son résultat : La spécialisation progressive des modèles a permis un gain d'un pourcentage de temps de 75 % dans la vérification de la mise en page. À la fin du projet, les résultats sont présentés avec des images des manuscrits, permettant de visualiser directement le travail effectué et l'efficacité de la transcription automatique.

Cependant l'évolution massive et continue de la transcription automatique mais elle rencontre toujours des challenges et des enjeux sous forme d'inconvénients plus précisément dans les documents historiques :

Premièrement cela est liée au manque de données variées et annotées :

En effet les modèles de Deep Learning nécessitent de grandes quantités de données pour apprendre rapidement et efficacement. Dans le domaine de documents historique, les manuscrits anciens sont rares et unique ce qui limite le volume de données annotées. Ainsi, les annotations demandent une expertise humaine, un travail humain (avoir des historiens, linguistes, des professionnels de domaine), ce qui rend le processus long et couteux, car cela demande de financement aussi. Donc, ce manque de données entraine des modèles moins robustes et parfois incapables de généraliser à de nouvelles ou inhabituées écriture, styles ou langues, tel que la langue arabe, son style et sa typographie qui change selon chaque style cursif de l'écrivain ou l'auteur de manuscrit.

Deuxième point, ce que on peut considérer comme inconvénients, ce sont les documents qui combinent de texte, graphiques, tableaux et chiffres :

Les documents historiques ne sont souvent pas purement textuels tels que : les cartes, registre et manuscrits scientifiques contiennent de texte mélangé à des graphiques et illustrations en formes de tableaux ou chiffre pour démonstration. Alors que les modèles standards de reconnaissance de texte sont généralement optimisés pour des lignes de texte continues horizontalement, donc les mises en page complexes ou des éléments non textuel posent une difficulté également pour ces modèles. Car cette diversité complique la segmentation automatique, la détection des lignes et des caractères, et cela résulte des erreurs d'interprétation des tableaux ou graphiques peuvent entrainer des transcriptions incomplètes ou incorrectes qui posent des limites de l'utilité et le fonctionnement du modèle destiné en particulier pour la recherche historique.

Enfin, d'après cette analyse, nous constatons la nécessité d'architectures adaptées à la reconnaissance de structures des langues complexes ou non latines :

La plupart des architectures de Deep Learning ont été développées pour l'alphabet latin, ce qui résulte que les scripts historiques non latins (l'arabe, le chinois...etc) ont des caractères imbriqués et des tailles variées et totalement différents d'alphabet latin, ce qui rend les modèles classiques inefficaces pour le traitement de ces langues. Dans le but d'améliorer cet aspect qui servira dans la recherche, il est désormais nécessaire d'améliorer ces modèles et les rend moins standardisé et les rendre plus spécialisés, pour qu'ils soient capables de reconnaitre des motifs complexes et à gérer la diversité des contenus et des scripts. Parce que sans architecture spécialisées selon chaque langue et typographie, la reconnaissance automatique continue à commettre des erreurs, surtout dans des textes avec des caractères rares ou des symboles uniques.

Bibliographie :

Lucas, N., Salah, C., &Vidal-Gorène , C. (2022). *New Results for the Text Recognition of Arabic Maghrib{ī} Manuscripts -- Managing an Under-resourced Script,.* Cornell University, arXiv: 2211.16147

Lucas, N. (2022). *2022. Hal-03822459 OCR/HTR et graphie arabe Les manuscrits arabes à l'heure de la reconnaissance automatique des écritures*

Lucas, N., et al. (2022). *RASAM I et II – A Dataset for the Recognition and Analysis of Scripts in Arabic Maghrebi Retour sur deux expériences de transcription collective et développement de datasets (2020-2022)*

Cloppet, F., et al. (2021). *Deep Learning for Historical Document Analysis and Recognition—A Survey*

Transcribia. (s.d). *Pourquoi la transcription automatique est utile ? - transcribia.fr*

Consulté sur https://transcribia.fr/

Consortium DISTAM – Huma-Num. (s.d.). Graphies Arabes et Transcription Automatique : Vers une Reconnaissance Textuelle Haute Précision – Carnet hypothèses du consortium Huma-Num DISTAM (DIgital STudies Africa, Asia, Middle East). Carnet Hypothèse. Consulté sur hypothses.org.

Deep Learning Deep Learning for Historical Document Analysis and Recognition—A Survey - PMC

Les collections de manuscrits maghrébins en France (1/2) - École de printemps du GIS MOMM

Les collections de manuscrits maghrébins en France (2/2) - École de printemps du GIS MOMM

Comprendre l'annotation de données : méthodes, équipes, outils